



Finální projekt Brain Tumor

31.03.2025

Roman Báňas, Kamila Houdek, Richard Pařík



Klasifikace nádorů

Cíl: vytvořit klasifikační model, který s vysokou přesností určí druh nádoru

Dataset: <https://www.kaggle.com/datasets/denizkavi1/brain-tumor>

3 druhy nádorů:

“Meningioma” - 708 fotek


"Glioma" - 1426 fotek

“Pituitary” (hypofýza) - 930 fotek

MRI - magnetická rezonance, přes 3000 barevných fotek ve formátu .png, původní rozměr 512 x 512 pixelů

Postup prací

- Prohlédnutí vzorku dat, příprava dat pro trénování modelu
- Zvažována změna barevné škály (barevné fotky → černobílé?)
- Rozhodování ohledně změny velikosti fotek
- Výběr modelů (MobileNetV2, VGG16, VGG19)
- Použití optimizerů (Adam, SGD s momentem)
- Studium dokumentace TensorFlow, Keras
- Použití Keras Tuneru





Příprava dat

Rozdělení datasetu do tří skupin:

- trénink modelu = 70 % fotek
- ověření výkonnosti modelu (validation) = 15 % fotek
- test modelu = 15 % fotek

Normalizace a škálování datasetu dle použitého modelu (funkce “preprocess_input”)

Augmentace - rotace (rotation), posun obrázků (shift), horizontální překlopení (horizontal flip) atd.


- zvolena pro trénovací data

Promíchání obrázků - u trénovacích dat před každou epochou (funkce “shuffle”)

MobileNetV2 - menší rozměr


Optimizer Adam

Formát 128 x 128



Opt. SGD (momentum 0.9)


Formát 128 x 128



MobileNetV2 - větší rozměr


Optimizer Adam

Formát 224 x 224



Opt. SGD (momentum 0.9)

Formát 224 x 224





Keras Tuner - hledání ideálních hyperparametrů

Tuning modelu VGG16

Učení modelu / dropout / počet neuronů

Learning rate

- Po cca hodině návrh nejlepší kombinace
- **Úprava učení modelu + learning rate**

```
Trial 14 Complete [00h 06m 11s]  
val_accuracy: 0.9718189835548401
```

```
Best val_accuracy So Far: 0.975234866142273  
Total elapsed time: 01h 04m 18s
```

```
Search: Running Trial #15
```

Value	Best Value So Far	Hyperparameter
1	1	trainable
256	256	units
0.2	0.3	dropout
0.0001	0.0001	learning_rate
7	7	tuner/epochs
0	3	tuner/initial_epoch
1	2	tuner/bracket
0	1	tuner/round



Nejlepší model - finální hyperparametry

Model **VGG16** - předtrénovaný model, umožněno další učení a fine-tuning na zvoleném datasetu

Global Average Pooling 2D redukuje počet trénovaných parametrů, zamezení over-fittingu

Hidden layers **Dense** (plně propojené), **256 neuronů**, **ReLU** aktivační funkce zlepšuje výkon

Dropout **0.3** pro zamezení over-fittingu

Output layer **Dense**, **3 neurony** (3 klasifikační třídy), **Softmax** aktivační funkce

Optimizer **Adam**, learning rate **1e-4 (0.0001)**

Early stopping - úspora času

Vítěz: VGG16



25 epoch

Validation Loss **0.0239**

Validation Accuracy **0.9918**

Test Loss **0.0224**


Test Accuracy **0.9906**



Confusion Matrix


Chyby: 5 fotek z testovacího vzorku nebylo správně klasifikováno

Diagonála: správně klasifikované nádory




Nesprávně klasifikované fotografie (příklady)


True Label: Glioma, Predicted: Meningioma




True Label: Meningioma, Predicted: Glioma




True Label: Meningioma, Predicted: Glioma



True Label: Glioma, Predicted: Meningioma



True Label: Pituitary, Predicted: Glioma



GradCAM - interpretace procesu rozhodování


GradCam vytváří “heatmap” dle významnosti prvků → větší pochopení rozhodování modelu.

Umožňuje dále ladit a zlepšovat model -
identifikuje zaujatosti nebo chyby
v rozhodovacím procesu.


GradCam provádí své úkony v poslední
konvoluční vrstvě modelu VGG16.

True & Predicted Label: Meningioma

Original (224x224)



Grad-CAM: Meningioma (Conf: 1.00)





Závěr a doporučení

- získat více dat pro robustnější trénování
- konzultovat výsledky s odborníky (lékař)
- nespolehat pouze na bezplatné nástroje
- včas uložit nejlepších výsledků (vah) pro navazující práci
- pro ještě větší přesnost více epoch bez “early stopping” - omezení je čas a peníze
- vyzkoušet pokročilejší architekturu modelu VGG19 - větší časová a výpočetní náročnost

```
accuracy: 0.9876 - loss: 0.0429 - val_accuracy: 1.0000 - val_loss: 0.0047
```